Ejercicios

1. Crear una notebook en su workspace y agregar el lakehouse "lh_origin_get_talent".
2. Mover todos los datos de la carpeta "shop_carrito" a la capa bronze y guardarlo como archivo parquet en Files.
3. Transformar los datos almacenados en bronze y guardarlos en una tabla delta en silver en el schema "shop_carrito". Cada archivo debe tener su tabla. Las transformaciones son a elección, mínimo 2 transformaciones (Si no se pueden las 2, las que se puedan). Para al menos dos de los datasets, la transformación se tiene que basar en consumir una API. La API y lo que haga la transformación es a elección también (Puede ser algo super simple como agregar una columna con el valor de la API).
4. En la capa gold, se tiene que almacenar una sola tabla del tipo OBT (One Big Table), es decir, combinar todas las tablas en una sola tabla gigante.
   La tabla debe contener las columnas que consideren relevantes para que alguien las consuma. Se puede hacer utilizando SparkSQL o PySpark, lo que les resulte más fácil.
   A tener en cuenta: No es anormal que la tabla tenga muchos NULL, de hecho, es bastante normal. No se tienen que remplazar esos NULLS de la tabla OBT.
   La cantidad de registros no puede ser inferior a la cantidad de registros que tenga el dataset con mayor cantidad de registros. Por ejemplo: Si el dataset con mayor cantidad tiene 50000, el resultado total de la tabla OBT, debe ser de 50000 o más.
5. Documentar lo hecho y explicar el por qué de las transformaciones hechas.
6. (Opcional) En la documentación, incorporar que otras transformaciones harían a los archivos en la capa silver.
7. (Opcional 2) Hacer un diagrama de arquitectura muy simple del proceso. Tips: Los diagramas pueden incluir: formato de archivo o del dataset, donde se almacenan, que se usa para transformar, herramientas, etc.

Ej de diagramas simples:

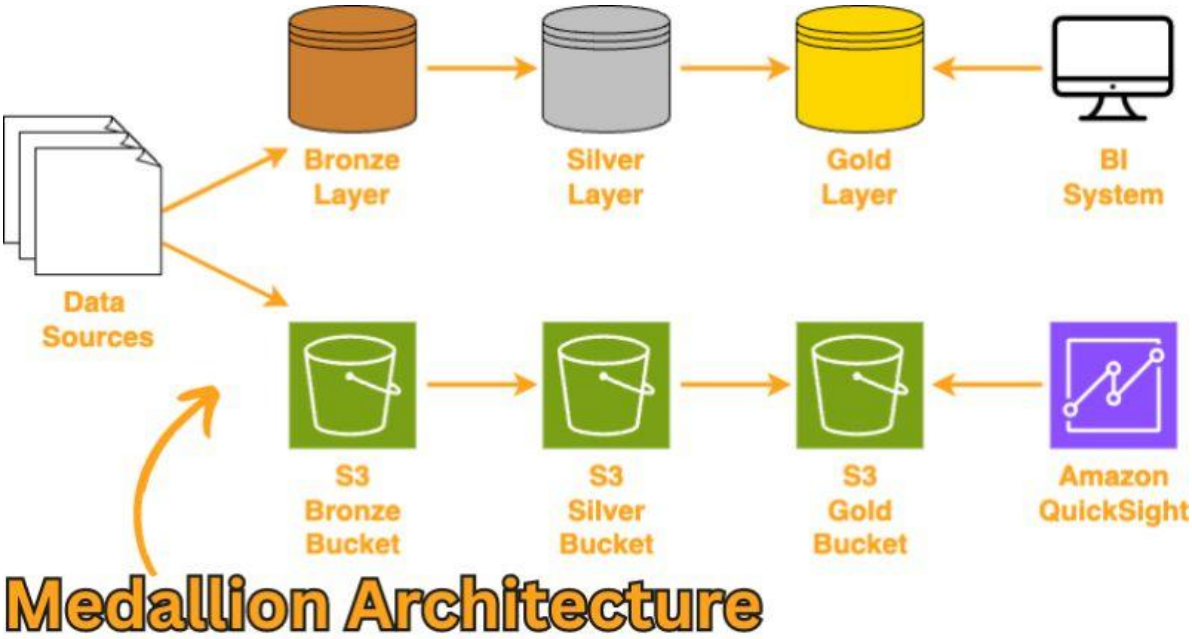

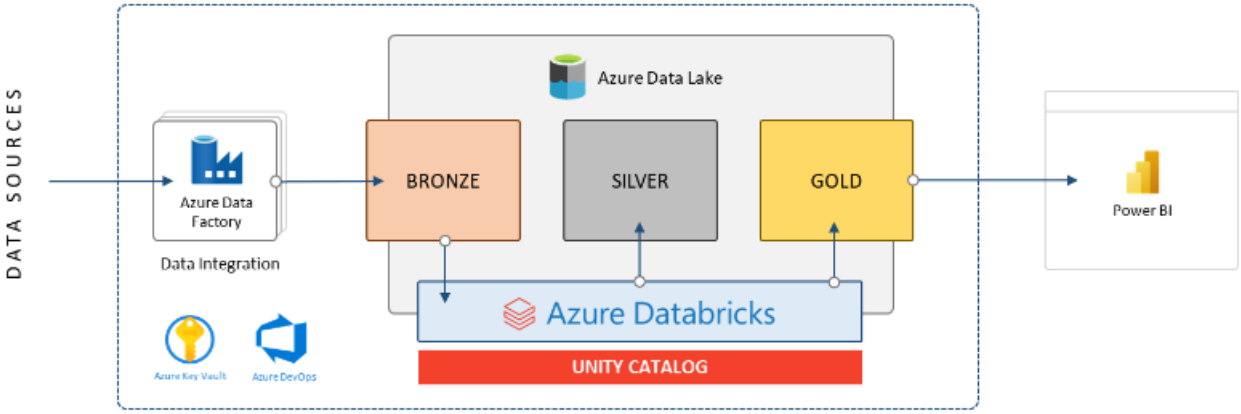

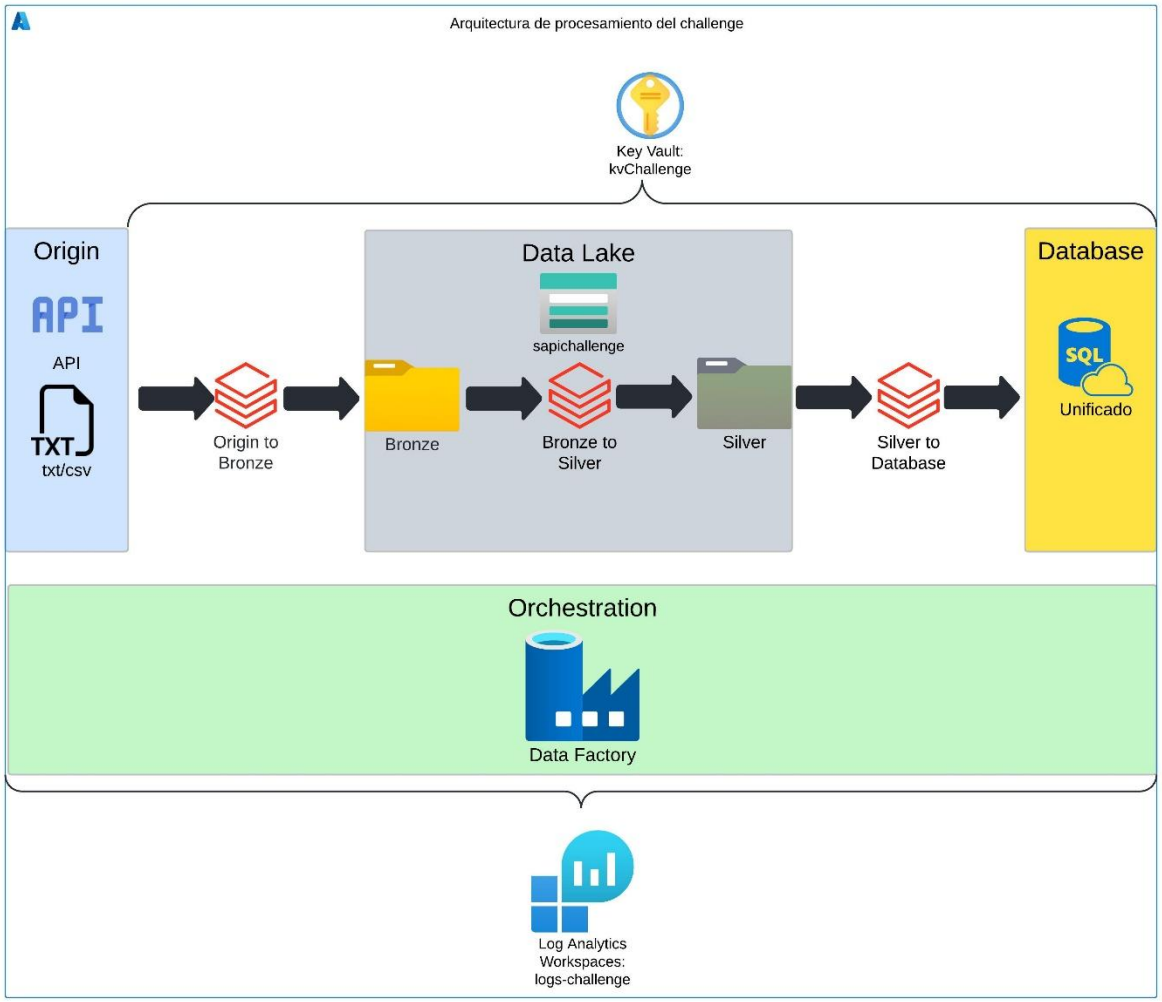
Arquitectura de procesamiento del challenge
Key Vault:
kvChallenge
Origin
API
API
TXT
txt/csv
Origin to
Bronze
Data Lake
sapichallenge
Bronze
Bronze to
Silver
Silver
Silver to
Database
Database
SQL
Unificado
Orchestration
Data Factory
Log Analytics
Workspaces:
logs-challenge

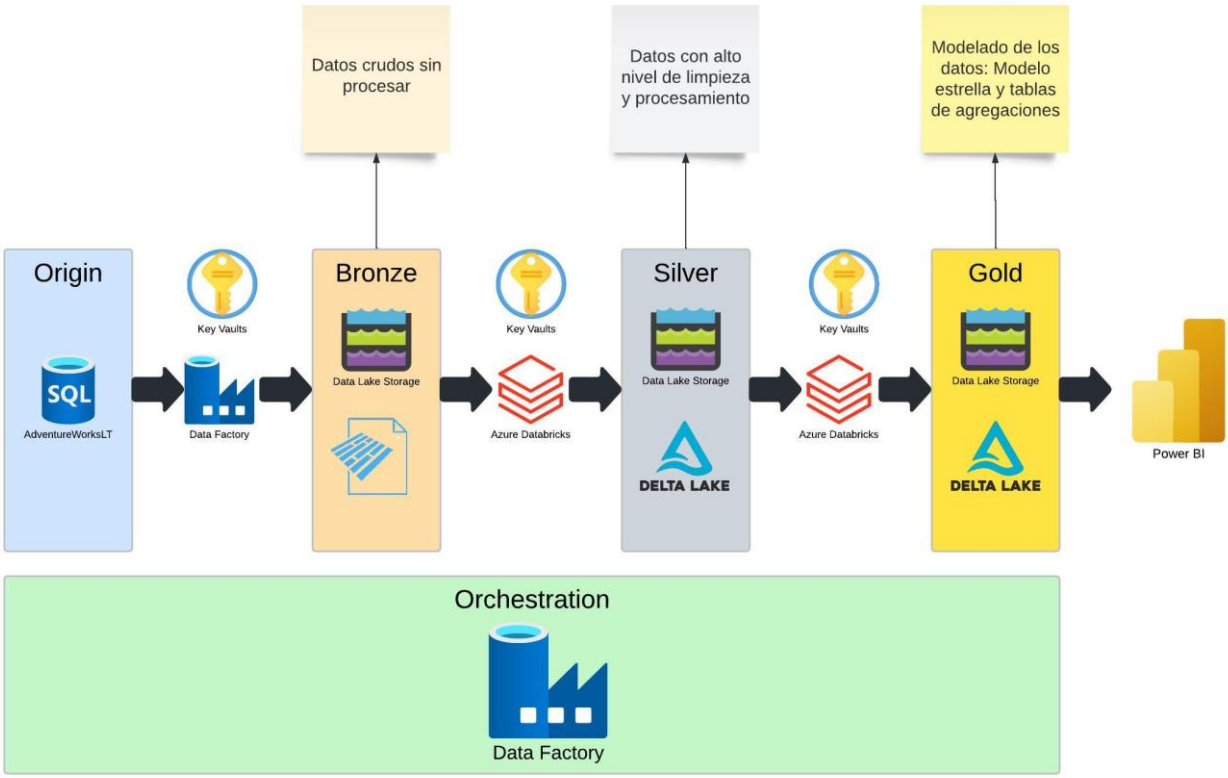
Datos crudos sin
procesar
Datos con alto
nivel de limpieza
y procesamiento
Modelado de los
datos: Modelo
estrella y tablas
de agregaciones
Origin
SQL
AdventureWorksLT
Key Vaults
Data Factory
Bronze
Data Lake Storage
Key Vaults
Azure Databricks
Silver
Data Lake Storage
DELTA LAKE
Key Vaults
Azure Databricks
Gold
Data Lake Storage
DELTA LAKE
Power BI
Orchestration
Data Factory

Requisitos de entrega: Debe haber al menos una notebook por capa (Bronze, Silver y Gold) y se deben utilizar títulos en las notebooks para entender que se está viendo, utilizando los Markdown de las notebooks. No hace falta ser super específicos. Por ejemplo, si se está trabajando el dataset de “artículos” El título puede decir solamente “Artículos”. Si le quieren agregar más nivel de detalle, no hay problema.
Se debe adjuntar la documentación del trabajo vía mail. también incorporar los links a las notebooks o exportar las notebooks y adjuntarlas (Como les parezca mejor). Importante: tener en cuenta, la documentación debe ser con formato de documentación, valga la redundancia (Básicamente que esté un poco estructurada, como la tarea pasada). El formato de la documentación queda a elección de ustedes también.

Fecha de entrega: 19/02 hasta las 23:59.
Importante: **Cualquier cambio que se haga en las fechas o de los requisitos de la entrega, también van a ser comunicados por Discord.**