Documentación de Solución
Pipeline de Ingesta de Datos

get Talent

ENGINEERING EDITION

Microsoft Fabric - AdventureWorks2019

Aprendiz : Euler Diego

Tabla de Contenidos

Tabla de Contenidos 2
1. Introducción 3
1.1 Objetivo del Proyecto 3
1.2 Alcance 3
2. Arquitectura de la Solución 3
2.1 Componentes Principales 3
2.2 Parámetros del Pipeline 4
3. Flujo de Datos 4
3.1 Diagrama de Arquitectura General 4
3.2 Lógica de Procesamiento (Pseudocódigo) 5
3.3 Diagrama de Secuencia de Ejecución 6
3.4 Descripción Detallada de Actividades 7
4. Estructura de Datos 8
4.1 Capa Landing (Raw Data) 8
4.2 Capa Bronze (Processed Data) 8
5. Características Técnicas de la Solución 8
5.1 Diseño Dinámico y Escalable 8
5.2 Gestión Inteligente de Cargas 8
5.3 Trazabilidad y Auditoría 9
5.4 Optimización de Almacenamiento 9

1. Introducción

El presente documento describe la implementación completa de la solución de ingesta de datos desarrollada en el Trabajo Práctico 4 (TP4), utilizando **Microsoft Fabric** y siguiendo la arquitectura Medallón.

1.1 Objetivo del Proyecto

La solución implementada tiene como objetivos principales:

- Ingestar 22 tablas de la base de datos AdventureWorks2019 mediante Data Gateway
- Implementar un pipeline dinámico y parametrizado que soporte cargas FULL e INCREMENTALES
- Almacenar datos crudos en la capa Landing (formato Parquet con compresión Snappy)
- Transformar y enriquecer datos en la capa Bronze (formato Delta con metadatos de trazabilidad)
- Externalizar la configuración de carga mediante un lakehouse de configuración

1.2 Alcance

El proyecto procesa las siguientes tablas de AdventureWorks2019:

- 3 tablas del esquema Production (carga FULL): Product, ProductSubcategory, ProductCategory
- 1 tabla del esquema Person (carga FULL): ContactType
- 18 tablas del esquema Sales:
  - 2 con carga INCREMENTAL: SalesOrderHeader, SalesOrderDetail
  - 16 con carga FULL
- Metadatos del esquema Sales extraídos desde vistas del sistema

2. Arquitectura de la Solución

2.1 Componentes Principales

La solución está compuesta por los siguientes elementos:

Componente	Descripción
Pipeline Principal	**pl_ingst_adw_full_incremental** - Orquesta la ingesta dinámica de las 22 tablas con ejecución paralela (batch size = 5)
Lakehouse Config	**lh_config** - Almacena la tabla config.table_load_config con metadatos de las 22 tablas (schema, table, load_type, folder_date_pattern, is_active)
Data Gateway	Conexión segura entre Microsoft Fabric (nube) y la base de datos AdventureWorks2019 on-premises
Lakehouse Landing	**lh_landing** - Almacena datos crudos en formato Parquet con compresión Snappy, organizados por: proyecto/fuente/<esquema>/<tabla>/AAAAMMDD/<tabla>_AAAAMMDD.parquet
Lakehouse Bronze	**lh_bronze** - Almacena tablas Delta con nomenclatura br_<esquema>_<tabla> y 5 columnas de metadatos: ingestion_date_ts, pl_run_id, process_date, load_type, exercise_number

2.2 Parámetros del Pipeline

El pipeline utiliza parámetros dinámicos para flexibilizar las cargas incrementales:

- fechaDesde: Fecha inicial para cargas incrementales (default: hoy - 1 día)
- fechaHasta: Fecha final para cargas incrementales (default: hoy)
- pl_run_id: ID de ejecución del pipeline generado automáticamente (@pipeline().RunId)

Nota: Los valores por defecto permiten ejecutar el pipeline sin intervención manual, procesando automáticamente los datos del día anterior hasta hoy.

3. Flujo de Datos

3.1 Diagrama de Arquitectura General

El siguiente diagrama ilustra la arquitectura completa de la solución, mostrando la interacción entre los diferentes componentes:

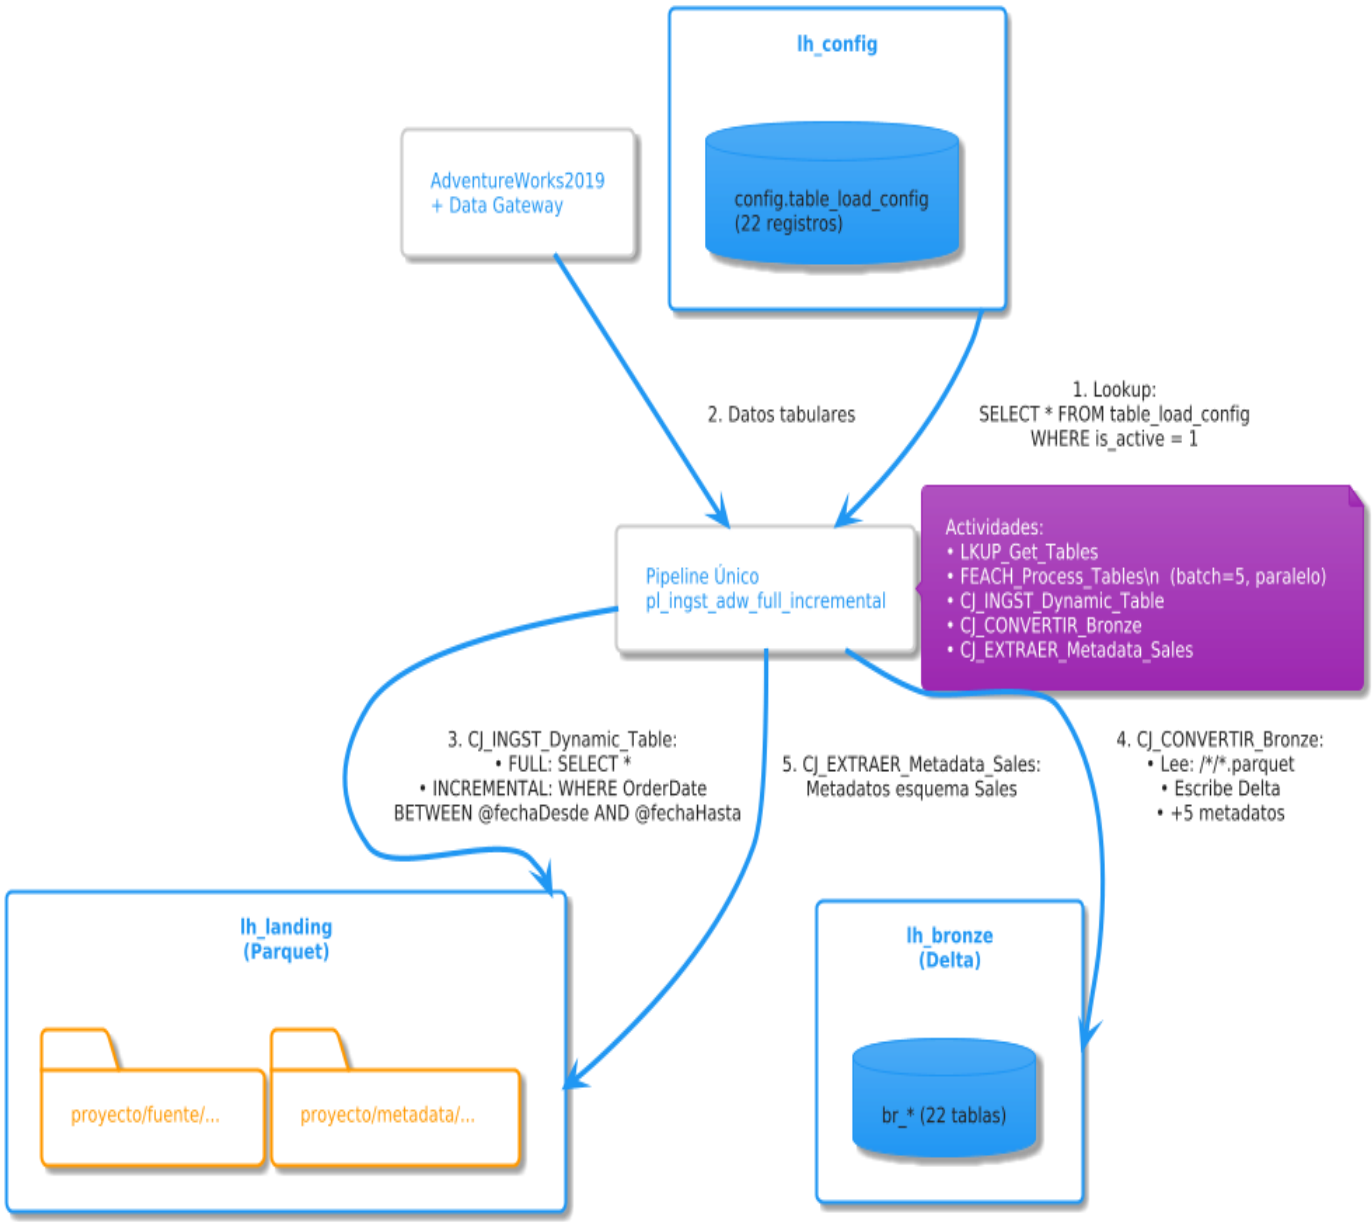

3.2 Lógica de Procesamiento (Pseudocódigo)

PIPELINE pl_ingst_adw_full_incremental

PARÁMETROS:

- fechaDesde: STRING (opcional, default: hoy - 1 día)
- fechaHasta: STRING (opcional, default: hoy)
- pl_run_id: STRING = @pipeline().RunId

INICIO

// PASO 1: Obtener configuración de tablas activas

tablas ← LKUP_Get_Tables(

- fuente = "lh_config.config.table_load_config"
- query = "SELECT * FROM table_load_config WHERE is_active = 1"

)

// PASO 2: Procesar tablas en paralelo (batch size = 5)

PARA CADA tabla EN tablas (batchCount = 5) HACER

// Subpaso 2.1: Extraer datos a Landing

CJ_INGST_Dynamic_Table(

- fuente = "AdventureWorks2019"
- query = SI tabla.load_type = "INCREMENTAL" ENTONCES
- "SELECT * WHERE OrderDate BETWEEN '" + COALESCE(fechaDesde, hoy-1) + "' AND '" + COALESCE(fechaHasta, hoy) + "'"
- SINO "SELECT *" FIN SI
- destino = "lh_landing/proyecto/fuente/" + tabla.schema + "/" + tabla.table + "/" + AAAAMMDD
- formato = Parquet con compresión Snappy

)

// Subpaso 2.2: Transformar a Bronze con metadatos

CJ_CONVERTIR_Bronze(

- fuente = "lh_landing/*/*/*.parquet" (wildcards para lectura dinámica)
- destino = "lh_bronze/br_" + tabla.schema + "_" + tabla.table
- acción = SI tabla.load_type = "INCREMENTAL" ENTONCES "Append" SINO "Overwrite"
- metadatos = {
- ingestion_date_ts: UTC_NOW(),
- pl_run_id: pl_run_id,
- process_date: AAAAMMDD_hoy,
- load_type: tabla.load_type,
- exercise_number: tabla.exercise_number
- }

)

FIN PARA

// PASO 3: Extraer metadatos del esquema Sales

CJ_EXTRAER_Metadata_Sales(

- fuente = "AdventureWorks2019"
- query = "SELECT s.name AS schema_name, t.name AS table_name FROM sys.tables t INNER JOIN sys.schemas s ON t.schema_id = s.schema_id WHERE s.name = 'Sales'"
- destino = "lh_landing/proyecto/metadata/sales_tables/AAAAMMDD/sales_tables_AAAAMMDD.csv"

)

RETORNAR "ÉXITO: 22 tablas procesadas en Bronze con metadatos"

FIN PIPELINE

3.3 Diagrama de Secuencia de Ejecución

El siguiente diagrama muestra la secuencia temporal de ejecución de las actividades del pipeline:

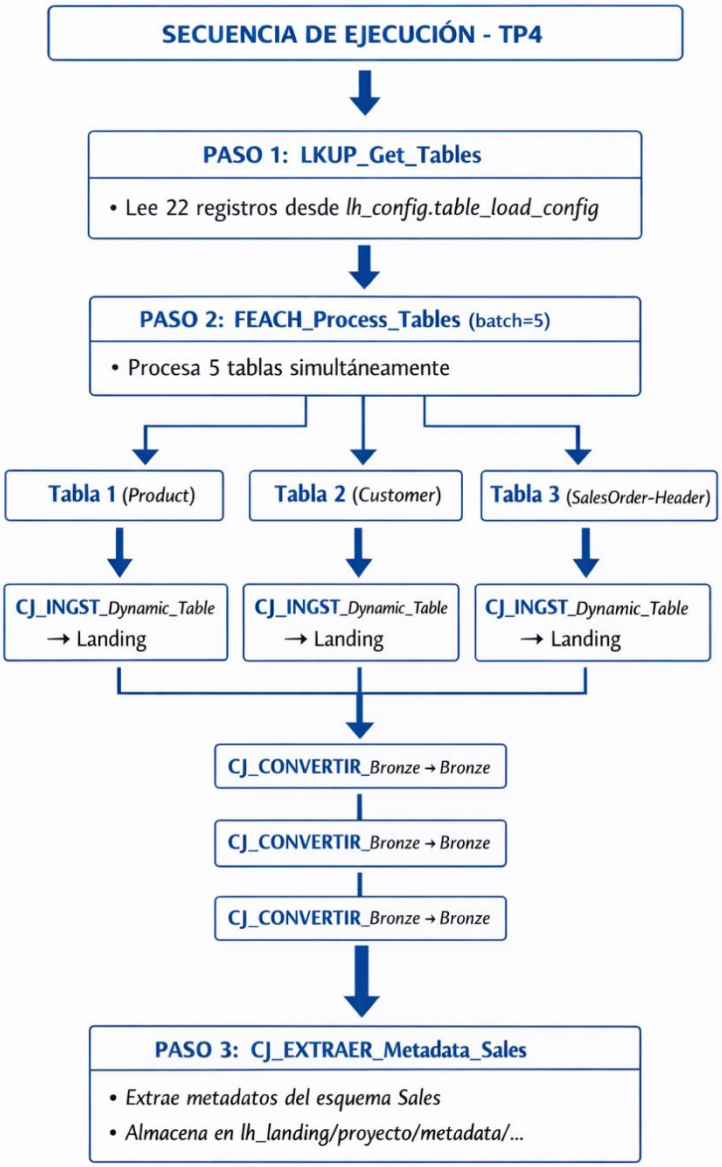

3.4 Descripción Detallada de Actividades

- **Paso 1: Actividad LKUP_Get_Tables**
  - Lee configuración de las 22 tablas desde lh_config.config.table_load_config
  - Retorna array con schema_name, table_name, load_type, folder_date_pattern

- **Paso 2: Actividad FEACH_Process_Tables**
  - Itera sobre las 22 tablas en lotes de 5 (ejecución paralela)
  - Para cada tabla ejecuta:
    - **CJ_INGST_Dynamic_Table:**
      - Tablas FULL: SELECT * FROM schema.table
      - Tablas INCREMENTALES: WHERE OrderDate BETWEEN @fechaDesde AND @fechaHasta
      - Escribe en lh_landing/proyecto/fuente/<esq>/<tab>/AAAAMMDD/<tab>_AAAAMMDD.parquet

    - **CJ_CONVERTIR_Bronze:**
      - Lee desde Landing con wildcards /*/*.parquet
      - Escribe en lh_bronze como tabla Delta br_<esq>_<tab>
      - Agrega 5 metadatos: ingestion_date_ts, pl_run_id, process_date, load_type, exercise_number

- **Paso 3: Actividad CJ_EXTRAER_Metadata_Sales (fuera del ForEach)**
  - Extrae metadatos desde sys.tables y sys.schemas donde schema = 'Sales'
  - Almacena enlh_landing/proyecto/metadata/sales_tables/AAAAMMDD/sales_tables_AAAAMMDD.csv

4. Estructura de Datos

4.1 Capa Landing (Raw Data)

Estructura de carpetas:

```
lh_landing/Files/proyecto/fuente/<esquema>/<tabla>/AAAAMMDD/<tabla>_AAAAMMDD.parquet
```

Ejemplo:

```
lh_landing/Files/proyecto/fuente/Sales/SalesOrderHeader/20240209/SalesOrderHeader_20240
209.parquet
```

Características:

- Formato: Parquet
- Compresión: Snappy
- Particionamiento: Por fecha (AAAAMMDD)
- Nomenclatura: <tabla>_AAAAMMDD.parquet
- Contenido: Datos crudos sin transformaciones

4.2 Capa Bronze (Processed Data)

Nomenclatura de tablas:

```
br_<esquema>_<tabla>
```

Ejemplo:

```
br_Sales_SalesOrderHeader
```

Esquema de metadatos:

Columna	Tipo	Descripción
`ingestion_date_ts`	TIMESTAMP	Timestamp UTC de la ingesta
`pl_run_id`	STRING	ID único de ejecución del pipeline
`process_date`	DATE	Fecha de procesamiento (AAAAMMDD)
`load_type`	STRING	Tipo de carga (FULL o INCREMENTAL)
`exercise_number`	STRING	Identificador del ejercicio (TP4)

5. Características Técnicas de la Solución

5.1 Diseño Dinámico y Escalable

- Pipeline único que procesa 22 tablas sin hardcoding de nombres o esquemas
- Configuración centralizada en lakehouse lh_config mediante tabla table_load_config
- Capacidad de activar/desactivar tablas modificando el campo is_active en configuración
- Fácil adición de nuevas tablas insertando filas en la tabla de configuración
- Paralelismo configurable (batchCount = 5) para optimizar tiempos de ejecución

5.2 Gestión Inteligente de Cargas

Cargas FULL:

- Sobrescritura completa de datos (Overwrite mode)
- Aplicadas a tablas maestras y de dimensión
- 20 de 22 tablas utilizan este modo

Cargas INCREMENTALES:

- Modo Append para acumulación de datos históricos

    - Filtrado por rango de fechas (WHERE OrderDate BETWEEN fechaDesde AND fechaHasta)
    - Aplicadas a tablas transaccionales: SalesOrderHeader, SalesOrderDetail
    - Parámetros con valores por defecto automáticos para ejecución sin intervención manual

5.3 Trazabilidad y Auditoría

- Cada registro en Bronze incluye 5 columnas de metadatos que permiten:
    - Identificar cuándo fue ingestado el dato (ingestion_date_ts)
    - Rastrear la ejecución específica del pipeline que lo procesó (pl_run_id)
    - Conocer la fecha de procesamiento (process_date)
    - Distinguir el tipo de carga aplicada (load_type)
    - Asociar con el número de ejercicio (exercise_number)
- Formato Delta Lake que proporciona ACID transactions y time travel
- Capacidad de auditar y regenerar cargas históricas

5.4 Optimización de Almacenamiento

- Formato Parquet en Landing con compresión Snappy para reducir tamaño de archivos
- Formato Delta Lake en Bronze para consultas eficientes y gestión de versiones
- Particionamiento por fecha en Landing para facilitar búsquedas temporales
- Wildcards en lectura de Landing para procesamiento dinámico sin conocer estructura exacta